

量化专题报告

“机器学习”选股模型系列研究（二）

量价指纹模型的迭代：行为选股与条件风格收益的协同建模

研究背景：前期报告《量价指纹模型的构建与应用初探》提出将日内量价序列视为一种特殊的“行为语言”，并通过自监督学习生成日级量价指纹。初版模型验证了行为指纹在收益预测和指数增强中的应用潜力，但进一步研究发现，若在预训练阶段直接引入收益方向目标，指纹可能同时记录交易行为和训练期收益偏好，在市场风格切换时影响表征的适应能力。基于此，本报告重新划分行为表征与收益预测的职责，对量价指纹模型进行系统迭代。

WPE 行为指纹的构建：本报告构建日内预训练编码器 WPE，以每只股票每日 237 分钟、62 项价格和微观交易特征为输入，通过预测后续买方压力、撤单压力、委托激进度、大资金参与、波动状态和流动性状态，学习 128 维日级行为指纹。WPE 预训练不使用未来股票收益，而是专注于描述资金如何参与、订单如何变化以及流动性如何演化；同时引入五个行为房间、行为一致性和房间正交约束，提高表征空间的信息组织能力。

CDE 结构化收益建模：在下游应用中，本报告构建 CDE 框架，将最近 20 个交易日的 WPE 指纹与日线价量状态共同输入 GRU，并通过 AlphaHead 和 BetaHead 分别表达个股收益规律与截面共同收益结构。CDE 的目标并不是将所有风格信息从选股信号中机械剔除，而是在风格内个股选择与条件风格收益之间进行平衡：AlphaHead 保留能够由历史行为状态稳定解释的选股信息，BetaHead 则在训练阶段为截面共同变化提供独立表达通道。正式部署使用 AlphaHead 输出，并由组合优化层控制最终行业和风格偏离，从而兼顾信号稳定性、收益厚度与指数增强中的风险约束。

模型表现与指数增强应用：回测区间 2021/01/04-2026/07/17 内，PureAlpha 因子的周度 RankIC 均值为 0.078，年化 RankICIR 为 5.66，十分组多空组合年化收益为 76.94%，信息比率为 6.02。经过市值和行业中性化后，因子周度 RankIC 均值仍达到 0.070，表明行为指纹能够在相同行业 and 相近市值股票内部形成有效排序。将基于国盛金工量价因子簇端到端模型构建的因子与指纹 PureAlpha 因子按 8:2 组合后，中证 1000 指数增强组合取得 17.30% 的超额年化收益，信息比率为 2.82，月度胜率为 78.18%，月度最大回撤为 3.17%；2026 年截至 7 月 17 日，超额收益由纯端到端模型的 4.72% 提高至 8.26%。

未来研究方向：后续研究将进一步完善行为房间和指纹空间的经济解释，引入基本面、事件信息、或者其他手工挖掘的微观量价特征。更重要的是，未来将探索如何结合市场风险偏好、流动性和波动状态，对相同交易行为进行条件化解读。研究重点不是机械剔除 Beta 信息，而是理解不同市场环境下，行为信息和 Beta 信息应当如何映射为收益。

风险提示：以上结论均基于历史数据和模型测算，市场环境及交易结构发生显著变化时，模型可能失效；单一模型收益可能存在较大波动，实际应用需结合组合优化、资金管理和风险控制；模型测算可能存在误差，不构成投资建议。

作者

分析师 沈芷琦

执业证书编号：S0680521120005

邮箱：shenzhiqi@gszq.com

分析师 刘富兵

执业证书编号：S0680518030007

邮箱：liufubing@gszq.com

研究助理 诸格慧明

执业证书编号：S0680125100009

邮箱：zhugethuiming@gszq.com

相关研究

- 1、《“机器学习”选股模型系列研究（一）：量价指纹模型的构建与应用初探》 2026-01-16
- 2、《“量价淘金”选股因子系列研究（十四）：基于流动性冲击事件的逐笔羊群效应因子——“高频数据+离散化”理念的具体实践》 2025-11-13
- 3、《“量价淘金”选股因子系列研究（十七）：基于订单聚集现象的高频量价因子研究》 2026-05-25

内容目录

一、前言	4
二、初版量价指纹模型回顾	6
三、新版量价指纹模型的构建	8
3.1 WPE 输入特征	8
3.2 WPE 模型结构	9
3.3 WPE 训练目标	10
3.4 WPE 模型年度更新	13
3.5 量价指纹的表征特征与经济含义	14
3.5.1 指纹空间具有持续的信息容量	14
3.5.2 指纹并非传统风格与价量指标的简单重编码	15
3.5.3 指纹具有股票层面的时间连续性	16
3.5.4 指纹距离具有明确的经济含义	17
3.5.5 固定股票群体可以识别真实的行为迁移	18
3.5.6 小结	19
四、量价指纹的端到端应用再探	20
4.1 传统机器学习模型的挑战	20
4.2 兼顾市场风格变化的指纹端到端模型	22
4.2.1 CDE 模型结构	22
4.2.2 CDE 训练与部署	24
4.2.3 Alpha 与 Beta 的分工逻辑	25
4.3 指纹 PureAlpha 单因子及指增效果检验	26
五、进一步讨论	29
5.1 指纹 PureAlpha 因子的跨指数增益	29
5.2 指纹 PureAlpha 因子的选股能力与风格适应性	31
5.2.1 市值与行业中性化检验	32
5.2.2 Barra 风格暴露分析	33
六、总结	36
风险提示	38

图表目录

图表 1: 初版量价指纹生成的前向和后向任务	6
图表 2: 初版量价指纹因子 10 分组净值走势	6
图表 3: 初版量价指纹因子 10 分组超额净值走势	6
图表 4: WPE 输入分钟级量价特征	9
图表 5: WPE 模型架构	10
图表 6: WPE 模型基础参数	10
图表 7: WPE 模型训练目标及含义	11
图表 8: WPE 模型训练目标的时间尺度	12
图表 9: WPE 模型的五房间设计	12
图表 10: WPE 模型的训练目标与五房间对应关系	12
图表 11: 指纹主要行为空间的信息容量与全市场状态变化	15
图表 12: 传统风格、行业与日线技术指标对指纹的历史解释率	16
图表 13: 同一股票与随机股票的跨期指纹相似度	17
图表 14: 指纹距离与未来收益绝对差的单调关系	18
图表 15: 指纹距离与未来收益同方向比例的单调关系	18
图表 16: 2024 年 2 月流动性冲击中的小微盘股票指纹迁移	19
图表 17: 2026 年 4-6 月科技股票指纹迁移	19
图表 18: 端到端因子 10 分组净值走势	20
图表 19: 端到端因子 10 分组超额净值走势	20
图表 20: 端到端因子分年度表现	21

图表 21:	端到端因子的中证 1000 指数增强组合净值	21
图表 22:	CDE PureAlpha 的模型架构	23
图表 23:	CDE 对个股收益的分解	25
图表 24:	指纹 PureAlpha 因子 10 分组净值走势	27
图表 25:	指纹 PureAlpha 因子 10 分组超额净值走势	27
图表 26:	指纹 PureAlpha 因子分年度表现	27
图表 27:	80%端到端+20%指纹 PureAlpha 因子的中证 1000 指数增强组合净值	28
图表 28:	不同因子对应的中证 1000 指数增强组合绩效指标对比	28
图表 29:	100%端到端因子的中证 500 指增组合净值	30
图表 30:	80%端到端+20%指纹 PureAlpha 因子的中证 500 指增组合净值	30
图表 31:	不同因子对应的中证 500 指数增强组合绩效指标对比	30
图表 32:	100%端到端因子的沪深 300 指增组合净值	31
图表 33:	80%端到端+20%指纹 PureAlpha 因子的沪深 300 指增组合净值	31
图表 34:	不同因子对应的沪深 300 增强组合绩效指标对比	31
图表 35:	市值、行业中性化后的 PureAlpha 因子 10 分组净值走势	32
图表 36:	市值、行业中性化后的 PureAlpha 因子 10 分组超额净值走势	32
图表 37:	市值、行业中性化后的 PureAlpha 因子 10 分组多空对冲净值曲线	33
图表 38:	指纹 PureAlpha 因子与几类 Barra 风格因子的相关性序列	34

一、前言

近年来，以 Transformer 和大规模预训练模型为代表的人工智能技术，正在推动研究范式由“人工定义特征”向“自主学习表示”转变。在自然语言处理中，模型通过预训练将词语、句子和篇章映射为具有结构的语义表示；在计算机视觉中，模型将局部纹理、形状和空间关系压缩为统一的视觉表征。其共同特征是：模型不再要求研究者事先规定每一项信息应当如何组合，而是通过具有明确结构的预训练任务，从高维序列中自主提取可供多种下游任务复用的信息坐标。

金融市场同样具有鲜明的序列性和结构性。股票一天的交易过程并不是价格、成交量、换手率等少数指标的简单堆叠，而是买卖双方通过成交、挂单、撤单和价格调整不断互动的动态过程。若以分钟为观察单位，每一分钟的价格变化、资金参与和订单供给可以理解为一个局部表达，日内连续发生的所有分钟则共同构成了一段完整的“行为叙事”。即使两只股票最终取得了相同的日度涨跌幅，其形成过程也可能完全不同：或许是来自于大资金的持续流入和稳定的订单承接，或许是来自于卖方集中撤单形成的流动性真空，亦或许是尾盘少量成交推动的价格跳升。传统日线指标记录了这些过程的结果，却难以完整区分结果背后的交易机制。

传统量价因子通过人工设计动量、反转、波动率、换手率、订单不平衡和资金流等指标，对复杂交易过程进行概括。这一方法具有经济含义明确、计算方式透明的优势，但每个因子通常只描述市场的一部分。随着因子数量增加，信息冗余、非线性交互和时序依赖的问题也随之凸显。更重要的是，同一个指标在不同环境中可能具有不同含义：成交放大既可能代表趋势得到确认，也可能意味着交易拥挤开始释放；价格回撤既可能对应风险恶化，也可能是资金持续承接过程中的短期调整。仅依靠固定公式，难以完整描述这些行为变量之间的联合关系及其演变过程。

基于这一认识，我们在前期报告《量价指纹模型的构建与应用初探》中提出了“量价指纹”的概念，尝试将市场交易视为一种特殊的行为语言，通过自监督学习将日内量价序列压缩为 128 维日级表示。初版模型验证了行为指纹在收益预测和指数增强中的应用潜力，也展示了表示学习可以提供传统量价因子之外的信息增量。但进一步研究发现，如果在指纹预训练阶段直接加入价格方向或收益相关目标，模型在学习交易结构的同时，也可能将训练期内长期有效的收益关系写入指纹。当市场风格发生显著变化时，这种历史收益映射可能削弱指纹作为通用行为表征的适应能力。

因此，本报告并不是对初版模型进行简单扩容，而是重新界定指纹预训练与下游收益预测的职责。指纹模型首先应当回答“市场正在以什么方式交易这只股票”，而不是在编码阶段直接回答“这只股票未来是否上涨”。只有将行为描述与收益判断适度分离，指纹才能成为可被不同下游模型和不同市场环境重复解释的基础表示。未来收益的方向、个股选择以及共同风格收益的处理，则交由下游模型完成。

本次构建的 WPE（Within-Day Pretrained Encoder）模型以股票日内 237 分钟、62 项价格与微观交易特征为输入，覆盖价格路径、成交与资金流、不同资金层级参与、挂单供给、订单激进度和撤单行为等多个层次。模型不使用未来股票收益作为预训练标签，而是根据当前已经发生的分钟序列，预测后续买方压力、撤单压力、委托激进度、大资金参与、波动状态和流动性健康状态。由于分钟级交易行为本身具有较强不确定性，WPE 进一步预测未来行为的条件分布，而非单一固定数值，使模型能够同时学习未来状态的中心位置与不确定程度。

为了使 128 维表示形成更有序的内部结构，WPE 还引入资金流、流动性、参与者、波动率和撤单五个行为房间。不同预测任务通过相应房间读取信息，并由行为一致性与房间正交约束共同引导潜在空间。五个行为房间并不是对 128 维表示进行机械分割，也不意味着某项原始特征只能进入一个房间，而是通过多任务梯度为潜在表示建立结构化的信息出口。最终得到的指纹既保留全天交易过程的综合信息，又在空间关系上反映样本之间的行为相似性。

在下游应用方面，本报告进一步构建 CDE（Cross Day Evaluator）的 PureAlpha 模型，将最近 20 个交易日的 WPE 指纹与日线价量状态共同输入 GRU，并在共享时序表示之上设置 AlphaHead 和 BetaHead。AlphaHead 负责输出正式部署的个股分数，BetaHead 则在训练阶段刻画截面共同收益结构。该设计并不追求将 Alpha 处理为对所有传统风格严格正交的残差，而是为个股收益规律和共同收益结构提供相对独立的表达通道，缓解单一预测同时承担全部个股差异与共同行情解释的压力。考虑到共同收益方向在样本外具有较强不确定性，正式部署仅使用 AlphaHead 输出的 PureAlpha 分数。


这种结构体现了本报告对指数增强问题的进一步理解。指数增强因子既需要在相同行业、相近市值及相似风险特征的股票内部保持选股能力，也需要在组合风险预算允许的范围保留一定的收益厚度。完全依赖风格倾斜，容易在风格反转时使整体排序同步失效；将所有共同信息彻底剥离，又可能使信号过薄，难以支撑实际组合收益。PureAlpha 并不在这两个极端之间进行简单选择，而是以行为驱动的个股选择为基础，同时允许长期、重复出现的条件收益规律进入 AlphaHead，并将最终风格偏离交由组合优化层进行控制。

本报告将围绕三条主线展开。第一，介绍 WPE 的输入特征、预处理方法、模型结构、分布式行为预测目标和表示约束，并通过信息容量、传统变量解释率、时间稳定性和指纹距离等检验，分析 128 维行为指纹的表征特征与经济含义。第二，介绍 CDE PureAlpha 的时序建模与 Alpha/Beta 分解逻辑，检验 WPE 行为表示能否转化为稳定的截面选股信息。第三，将 PureAlpha 与现有端到端因子进行结合，在中证 1000、中证 500 和沪深 300 指数增强框架下考察其收益增量、风险特征和适用边界。

二、初版量价指纹模型回顾

在专题报告《量价指纹模型的构建与应用初探》中，我们采用 Causal Transformer 架构，将每只股票每日 237 分钟的微观交易数据编码为 128 维行为指纹向量。模型通过两个自监督任务进行预训练：其一是使用因果掩码预测分钟级收益率方向，其二是双向掩码重建被遮蔽的资金流特征，如图表 1 所示。预训练完成后，下游采用 GRU 模型读取过去 20 个交易日的指纹序列，直接输出截面选股分数。


图表1：初版量价指纹生成的前向和后向任务



资料来源：国盛证券研究所绘制


在 2021-2025 年的市场环境中，初版量价指纹模型展现了良好的全市场截面排序能力，尤其在沪深 300、中证 1000 等指数增强应用场景中贡献了稳定的超额收益。进入 2026 年以来，市场行情开始多变，1-3 月模型依旧保持着比较好的多头超额表现，但 Q2 以来多头超额开始连续回撤。图表 2、图表 3 展示了初版指纹因子的 10 分组净值走势、10 分组超额净值走势。

图表2：初版量价指纹因子 10 分组净值走势



资料来源：Wind，通联数据，国盛证券研究所

图表3：初版量价指纹因子 10 分组超额净值走势



资料来源：Wind，通联数据，国盛证券研究所

模型在 4-6 月科技抱团行情下持续回撤，我们认为主要有以下两点原因：第一，预训练阶段引入了收益方向预测任务。这使得 Transformer 编码器在提取行为特征的过程中，天然嵌入了训练期内长期有效的风格偏好。2018-2025 年间，低波动率、低流动性、偏小市值的股票在大多数年份表现出持续的正向风险溢价，这些风格特征被深度编码进了

128 维指纹空间——偏差的源头在指纹生成阶段，而非下游 GRU 引入。当 2026 年 4-6 月市场风格方向发生系统性反转，领涨群体切换为高波动、高 Beta、高流动性、偏大市值的科技和成长股时，指纹空间所学的“好股票应该是什么样”与市场实际的奖励方向恰好相反。第二，即使指纹完全纯净，只描述行为、不携带任何风格偏好，同一个行为在不同市场环境下仍然可能对应截然不同的含义。初版模型试图用单一固定映射“行为到收益”覆盖所有市场状态，不同环境下出现的同一种行为模式被强行压缩为同一个预测值，模型只能学到历史平均关系，一旦市场环境切换导致这一平均关系发生反转，模型无从得知，也不具备条件化修正的能力。

因此，我们认为指纹模型可以基于两个关键“分离”进行迭代：

(1) 指纹的预训练应与收益率解耦。指纹的目标不应是预测“什么会涨”，而是学习市场行为动力学本身——预测买方压力、撤单行为、波动状态、流动性变化等行为变量。这些预训练任务完全不接触收益率，确保指纹空间只编码“市场正在发生什么”，而不嵌入“历史上发生了什么现象后，股票开始上涨”。一个 return-free 的指纹，才是一个更好的表征，才有可能在风格反转时降低被训练期的收益映射所污染的概率。

(2) 下游模型需要对收益本身进行结构化分解。同一个行为在不同市场环境下对应的收益可以拆为两层：一层来自个股行为在同类股票中的相对优势，方向相对稳定；另一层来自当前市场环境对某一类行为的整体奖励或惩罚，方向随环境变化。训练时两者协同解释收益截面，但部署时应保持诚实——只有方向稳定、可复现的部分进入因子排序；方向随环境变化的部分，只有在能够可靠识别当前市场语境的环境下才被激活，否则仅作为训练约束和归因工具进行保留。

三、新版量价指纹模型的构建

如前所述，初版指纹模型中，我们设计了两类任务学习分钟级表示：一类根据此前若干分钟的量价与交易特征预测随后价格表现，另一类随机遮盖部分分钟特征并要求模型恢复原始输入。前者能够让表示快速获得短周期收益预测能力，后者能够利用特征之间的统计联系。但两者都有一些局限：价格预测会把训练期内“某种行为对应上涨还是下跌”的历史关系直接固化进指纹；遮盖重构则更容易学习到相邻分钟的平滑性，造成特征冗余。模型可能很擅长恢复数据或复现历史价格规律，却未必真正理解买卖力量、撤单行为、资金参与和流动性状态如何演化。

借鉴大语言模型的设计哲学，GPT 不是先学习“如何回答问题”，而是先学习语言本身的结构——通过因果语言建模目标 $P(x_{t+1}|x_{\leq t})$ ，学习对预测未来 token 有用的表示，下游任务再在这个预训练表示上微调。我们本次迭代，对指纹模型的预训练任务进行了同样的改进，WPE 遵循同样的逻辑：不是先学习“什么会涨”，而是先学习市场行为本身的动力学—— $P(x_{t+1}|x_{\leq t})$ 。

WPE 可以理解为一套面向股票日内行为序列的预测式编码器。它并不是直接预测未来股票收益的 Alpha 模型，也没有在训练阶段使用未来几日涨跌幅作为监督信号。它的核心任务是读取股票最近一个交易日共 237 分钟位置上的订单流、参与者结构、流动性、撤单、成交和价格状态，学习一个能够概括当日交易行为的低维向量，最终保存的是供后续 CDE 模型、市场状态识别或其他下游模型使用的“行为指纹”。

从建模逻辑上来说，WPE 解决的是“市场正在以什么方式交易这只股票，以及这种交易行为在日内如何演化”的问题，而不是直接回答“这只股票未来五天会涨多少”。为了避免模型退化成只会复制输入的普通自编码器，本次迭代中，WPE 不再采用输入重构目标，而是要求模型利用截至当前分钟的历史信息，预测之后若干分钟的买方压力、撤单压力、激进成交、参与者变化、波动状态和流动性健康状态。只有包含可延续行为结构的信息，才有助于完成对这些未来行为进行推演的任务，因此最终得到的日级表示更接近“可预测的交易机制摘要”，而不是简单的量价统计压缩。

这一区分对理解整个系统很重要。WPE 学到的行为指纹本身不等于纯 Alpha，不保证与 Barra 风格、行业完全无关。某些交易行为天然会与高波动、高流动性、小市值或拥挤交易同时出现，因此指纹可能携带这些状态信息。是否将这些信息解释为 Alpha、Beta、风险或市场环境，是下游收益模型的职责。WPE 的设计目标是尽量完整且稳定地描述行为，而不是在编码阶段提前删除所有与收益风格相关的成分。

3.1 WPE 输入特征

WPE 每天使用 237 个分钟位置，上午 09:30 至 11:29 对应 120 个位置，下午 13:00 至 14:56 对应 117 个位置。62 项输入特征覆盖从价格结果到订单供给的多层行为信息，图表 4 展示了我们具体使用到的分钟级特征。

WPE 的输入并不是将 62 个原始字段直接送入 Transformer，预处理需要同时解决除权除息、绝对价格差异、股票规模差异和日内季节性的问题。对于五个价格字段，我们将其复权后除以该交易日的前一日收盘价；而对于成交、订单、参与者和撤单等同时受到股票规模和日内季节性影响的变量，WPE 为每只股票、每个分钟位置、每个字段计算过去 20 日均值，目标日直接对每个字段除以该均值，大于 1 则说明相对自身历史同期更加活跃，小于 1 则说明相对自身历史同期更加冷清。

WPE 的 62 维分钟特征并不只是更多的技术指标，而是对交易过程不同环节的观察。挂单体现交易意图，成交反映意图实现后的结果，撤单则反映原有意图的撤回或否定；不同资金层级的买卖活动描述市场参与者结构；价格路径和波动变化描述这些行为最终作用于市场后的状态。

图表4: WPE 输入分钟级量价特征

行为层次	特征数	主要内容
价格路径与价格位置	6	分钟开盘价、最高价、最低价、收盘价、VWAP、涨跌停区间位置
成交流	8	成交量、成交额、成交笔数、主动买卖成交额、主动买卖成交量、平均每笔成交额
参与者结构	16	超大、大、中、小单的主动买卖成交量与成交笔数
挂单供给与订单激进度	21	挂单总额、挂单总量、挂单笔数，大单挂单结构，买卖两侧 agg1~agg5 订单激进度
撤单状态	11	撤单总额、撤单总量、撤单笔数，买卖两侧超大单和大单撤单量与撤单笔数

资料来源：国盛证券研究所绘制

从这个角度看，一天的分钟序列可以被理解为一组“交易行为语言”。持续大单买入、较低撤单和缓慢价格推升，可能共同构成吸筹行为；订单供给下降、撤单加速和激进成交上升，可能共同表征流动性脆弱。WPE 的目标不是人工规定这些组合，而是让模型从大量样本中学习它们在时间上的共现与转移规律。


3.2 WPE 模型结构

模型首先将 62 维特征送入固定因子化投影：

$$h_t^{(0)} = (x_t \odot s)U, \quad U \in \mathbb{R}^{62 \times 128}$$

其中 $s \in \mathbb{R}^{62}$ 为可训练的逐特征尺度。固定投影的主要作用是减少可训练输入参数，并为年度更新提供相对稳定的入口坐标。投影后加入固定正弦位置编码和可学习分钟位置编码，再通过四层因果 Transformer，具体模型结构如图表 5 所示，模型的一些超参数、细节如图表 6 所示。

图表5: WPE 模型架构



资料来源: 国盛证券研究所绘制

图表6: WPE 模型基础参数

模型组件	当前配置	功能
输入维度	62	分钟微观行为特征
Transformer 隐藏维度	128	统一行为表示空间
Transformer 层数	4	提取多层时序交互
注意力头数	4	学习不同时间依赖
前馈层维度	512	非线性特征变换
激活函数	GELU	网络非线性
Dropout	0.2	控制过拟合
分钟位置	237	当日分钟序列
CLS token	1	汇总全天行为
Room 维度	24	五个任务投影视角
深层指纹	128	第四层 CLS, 即 z_day

资料来源: 国盛证券研究所绘制

因果掩码保证分钟位置 m 只能使用截至当时的信息:

$$h_m = f(x_{\leq m})$$

CLS token 位于序列末尾, 因此可以汇总全天 237 个分钟。第四层 CLS 形成:

$$z_{\text{day}} = h_{\text{CLS}}^{(4)} \in R^{128}$$

3.3 WPE 训练目标

WPE 不使用未来股票收益, 也不试图重构某些分钟特征, 而是对六类行为目标施加监督。目标覆盖下一分钟、未来 10 分钟和未来 30 分钟三个尺度, 训练目标如图表 7、图表 8 所示。具体而言, 六类预测目标分别刻画交易行为的不同侧面: 买方压力衡量主动买入成交额占比, 反映买卖方向的短期延续; 撤单压力追踪撤单额相对挂单总额的变化, 捕

捉订单供给的稳定性；委托激进度描述激进行为是否增强；大资金参与方向识别超大单与大单参与度的升降趋势；波动状态判断未来波动处于个股历史同期的低、中、高分位；流动性危机则检测挂单深度下降且订单激进度上升的异常状态。

同时，我们要求模型预测未来行为的概率分布，而不是单一固定值。主要原因是分钟级交易行为具有明显的不确定性：即使两只股票当前的订单流、参与者结构和流动性状态十分相似，下一分钟也未必产生完全相同的买卖压力或撤单强度。若只预测一个数值，模型主要得到条件均值，无法区分“未来结果稳定地集中在均值附近”和“均值相同但实际结果高度分散”这两种状态。分布预测则同时描述结果最可能出现的位置以及预测的不确定程度，更符合微观行为的随机性。不同任务采用的概率分布并非任意指定，而是由目标变量的取值范围和分布形态决定。以 Beta 分布任务为例，模型不直接输出一个买方压力预测值，而是输出两个正参数 a_i, b_i ：

$$Y_i \sim \text{Beta}(a_i, b_i), \quad \mathbb{E}[Y_i] = \frac{a_i}{a_i + b_i}.$$

其中， a_i, b_i 不仅决定分布均值，也决定概率质量是集中在 0 附近、1 附近还是区间中部，以及分布是尖锐还是分散。训练时采用负对数似然：

$$L_{\text{Beta}} = -\frac{1}{N} \sum_{i=1}^N \log p_{\text{Beta}}(y_i | a_i, b_i).$$

如果真实结果 y_i 位于模型赋予较高概率的位置，则损失较小；如果真实结果落在模型认为几乎不可能出现的位置，损失就会显著增大。LogNormal 任务采用完全相同的原则，只是模型输出适合非负长尾变量的 μ_i, σ_i ：

$$Y_i \sim \text{LogNormal}(\mu_i, \sigma_i), \quad L_{\text{LogNormal}} = -\frac{1}{N} \sum_{i=1}^N \log p_{\text{LogNormal}}(y_i | \mu_i, \sigma_i).$$

因此，所谓“预测分布”并不是增加一项抽象的统计设定，而是让损失函数直接回答：真实发生的未来行为，在模型事前给出的概率判断中有多合理。

图表7: WPE 模型训练目标及含义

行为目标	目标含义	模型输出	实际作用	原因
买方压力	主动买入成交额占总成交额的比例	Beta 分布	学习买卖方向的短期延续	Beta 分布天然限定在 (0,1)，可表达偏向 0、偏向 1 或集中在中间等不同形态
撤单压力	撤单额相对挂单总额的比例	LogNormal 分布	学习挂单方撤退和流动性变化	撤单比例不能为负，且多数时候较小、少数时候突然放大，符合右偏长尾特征
委托激进度	下一分钟 agg1+agg2 占全部激进度层级的比例	Beta 分布	学习抢成交行为是否增强	Beta 分布天然限定在 (0,1)，可表达偏向 0、偏向 1 或集中在中间等不同形态
大资金参与方向	超大单与大单参与度相对当前是下降、稳定还是上升	三分类	识别大资金参与是否持续	目标本身是分类状态
波动状态	未来波动位于个股自身历史同时间段的低、中、高分位	三分类	识别波动扩张和高波状态	目标本身是分类状态
流动性危机	挂单深度显著下降且订单激进度显著上升	二分类	识别订单簿流动性是否恶化	目标本身是分类状态

资料来源：国盛证券研究所绘制

图表8: WPE 模型训练目标的时间尺度

尺度	权重	主要任务	目标意义
下一分钟	0.5	买方压力、撤单压力、委托激进度	捕捉局部行为连续性
未来 10 分钟	0.3	买方压力均值、大资金参与状态	捕捉资金行为持续性
未来 30 分钟	0.2	波动状态、流动性危机	捕捉较慢的风险状态转换

资料来源: 国盛证券研究所绘制

每分钟的 128 维共享隐藏状态 h_m 承载了前面若干分钟的所有行为信息, 但不同预测任务需要关注的侧重点不同——买方压力更依赖资金流向的短期变化, 撤单压力更依赖挂单供给的稳定程度。如果让所有预测任务不加区分地从同一套 128 维表示中读取信息, 模型容易将不同任务的信息相互混淆, 降低指纹的结构化程度。

为此, 在每一分钟, 模型并不直接用该分钟 128 维的隐状态 h_m 去预测上面六类行为目标的概率分布, 而是先投影到资金流、流动性、参与者、波动率和撤单五个 24 维行为房间, 如图表 9 所示, 每个房间由不同预测任务的梯度引导形成特定视角, 不同预测任务再去读取与其最相关的房间组合进行相应的预测, 如图表 10 所示: 买方压力主要读取资金流与参与者房间, 撤单压力主要读取撤单与流动性房间, 波动状态则综合读取全部五个房间。

图表9: WPE 模型的五房间设计

模型 Room	输出维数	主要服务的目标	应如何理解
flow	24	买方压力、大资金参与、委托激进度	由资金流相关任务引导形成的投影视角
participant	24	买方压力、大资金参与	由参与者变化任务引导形成的投影视角
liquidity	24	撤单压力、委托激进度、流动性危机	由订单供给和流动性任务引导的投影视角
volatility	24	未来 30 分钟波动状态	由波动状态任务引导形成的投影视角
cancel	24	撤单压力、流动性危机	由撤单和订单簿恶化任务引导的投影视角

资料来源: 国盛证券研究所绘制

图表10: WPE 模型的训练目标与五房间对应关系

预测目标	读取的 Room
买方压力	flow + participant
大资金参与方向	participant + flow
撤单压力	cancel + liquidity
委托激进度	liquidity + flow
波动状态	全部五个 Room
流动性危机	liquidity + cancel

资料来源: 国盛证券研究所绘制

五个房间的核心作用, 是为 128 维表示建立有序的信息出口。预测头不再毫无约束地从全部维度中寻找捷径, 而是通过不同投影通道读取信息; 梯度反向传播后, 主干表示也会逐渐形成面向不同机制的内部组织。5 个 Room 的作用不是将 128 维机械切成五段, 也不是保证每个原始字段只能进入某个 Room, 而是通过“多任务预测头-独立投影-正交约束”的联合训练, 为 128 维表示施加结构化引导。其目标可以概括为:

无结构的共享表示 → 具有功能分工、同时保留跨行为联系表示

除未来行为预测外，模型还加入行为一致性和房间正交两类表示约束。设第 i 个样本由六类预测目标汇总得到行为摘要为 b_i 。模型首先按照摘要距离构造目标相似度：

$$S_{ij}^{\text{target}} = \exp\left(-\frac{\|b_i - b_j\|_2}{0.5}\right).$$

与此同时，128 维日级指纹之间的相似度定义为：

$$S_{ij}^z = \frac{z_i^\top z_j}{\|z_i\|_2 \|z_j\|_2}.$$

行为一致性损失要求指纹空间中的两两关系逼近目标行为所定义的关系：

$$L_{\text{cons}} = \frac{1}{B^2} \sum_{i=1}^B \sum_{j=1}^B (S_{ij}^z - S_{ij}^{\text{target}})^2.$$

这一约束并不规定某一维必须代表某个具体变量，而是要求整个潜在空间的几何结构具有行为意义：未来行为相似的样本应当更接近，未来行为差异较大的样本应当被拉开。

另一方面，若五个行为房间最终学成高度相似的表示，房间设计就会失去意义。设样本 i 的第 a 个日级房间表示为 $r_i^{(a)}$ ，房间正交损失定义为不同房间余弦相似度绝对值的均值：

$$L_{\text{ortho}} = \frac{1}{B \binom{5}{2}} \sum_{i=1}^B \sum_{1 \leq a < b \leq 5} \left| \frac{(r_i^{(a)})^\top r_i^{(b)}}{\|r_i^{(a)}\|_2 \|r_i^{(b)}\|_2} \right|.$$

最终训练目标为：

$$L = L_{T1} + 0.3L_{\text{cons}} + 0.01L_{\text{ortho}}.$$

其中， L_{T1} 是六类未来行为任务构成的主损失， L_{cons} 负责组织指纹空间， L_{ortho} 负责维持房间分工。主任务权重为 1，行为一致性权重为 0.3，房间正交权重为 0.01，体现“预测未来行为是主体、空间组织是辅助、房间解耦是弱约束”的设计顺序。验证和早停主要依据样本外行为预测损失，而不是收益 IC，因此 WPE 在模型选择阶段仍保持与收益无关的行为编码定位。

3.4 WPE 模型年度更新

市场行为会变化，模型需要定期吸收新样本；但如果每年完全重新初始化，潜在空间可能发生任意旋转，使历史指纹和下游模型失去可比性。因此，我们对 WPE 进行年度更新时，同时采用模型初始化继承、对比蒸馏和参数 EMA 的设置。

学生模型从旧模型参数开始训练，并通过 NT-Xent 约束新旧模型对同一样本的 z_{day} 保持相近的相对几何结构。设学生表示为 u_i ，冻结旧模型生成的教师表示为 v_i ，单个表示空间的对比蒸馏损失为：

$$L_{\text{NTX}}(u, v) = -\frac{1}{B} \sum_{i=1}^B \log \frac{\exp(\text{sim}(u_i, v_i)/\tau)}{\sum_{j=1}^B \exp(\text{sim}(u_i, v_j)/\tau)}, \quad \tau = 0.3.$$

其中，正样本是同一股票同一交易日在新旧模型下的表示，其他样本作为对比项。年度更新阶段的训练目标写为：

$$L_{\text{annual}} = L_{\text{WPE}} + 0.01L_{\text{NTX}}^z$$

该约束保留的是样本之间的相对几何关系，而不是机械要求新旧模型每个潜在维度逐点相等。训练结束后，参数进一步按下式混合：

$$\theta_{\text{final}} = 0.3\theta_{\text{old}} + 0.7\theta_{\text{best-new}}.$$

这套机制并不要求每个潜在维度永远不变，而是在适应最近行为模式的同时，降低年度更新造成的坐标突变。对于需要长期保存、聚类 and 滚动训练下游模型的行为指纹而言，表示连续性与单次训练损失同样重要。

通过以上模型设计，WPE 将一只股票的分钟级微观结构数据——成交、挂单、撤单、大中小单分层、订单激进度——压缩为一个行为指纹 z ，而非压缩后的 K 线。这个指纹描述的是“这只股票今天被怎么交易了”：买方还是卖方在主导？大资金在持续介入还是撤退？挂单方在加厚流动性还是在撤退？市场在从容挂单等待成交，还是在激进地抢成交？两只股票即使当天涨跌幅相同，如果一只由持续大单买入和健康订单供给推动，另一只由撤单上升、流动性下降和少量激进成交推动，它们的指纹应当不同。反之，不同行业和价格水平的股票，如果其参与者结构、买卖压力和订单演变相似，指纹可能相近。这意味着 WPE 的价值不只体现在直接提高某个收益模型的 IC，还体现在建立了统一的行为比较基础。指纹可以用于寻找行为相似股票、识别状态迁移、刻画极端行情下的点云漂移、监测拥挤与流动性风险，也可以作为多个下游选股模型的共享输入。

值得说明的是，WPE 当前采用的“预测未来行为”预训练任务，并不意味着第一版中“预测价格表现”或“遮盖重构”的设计是错误的。两类任务的适用性取决于最终目标：如果模型需要快速获得与收益相关的表征，价格预测是更直接的路径；如果目标是对市场交易行为本身建立通用且可迁移的表示，则行为预测更合适。WPE 选择后者，本质上是在“与收益信号的对齐程度”和“行为描述的完整性”之间做了取舍——前者可能带来更高的短期预测精度，后者则希望为下游提供更稳定、更可解释的行为底座。不同的应用场景对应不同的设计选择，第一版指纹模型在当时的任务设定下仍然是合理且有效的。

3.5 量价指纹的表征特征与经济含义

前文从模型结构和训练目标说明了 WPE 如何为每只股票每天生成 128 维行为指纹，本节进一步从全历史截面结构、传统变量解释率、时间连续性、指纹距离的经济含义以及固定股票群体的状态迁移这五个角度，检验该表示是否真正包含稳定且可复用的信息。相关检验只在事后用于理解指纹，不参与 WPE 训练，因此不会改变 WPE 不接触未来收益的预训练原则。


3.5.1 指纹空间具有持续的信息容量

为了在统一坐标下比较不同时期的指纹结构，我们首先使用历史样本拟合一套固定的主成分坐标，并在前 20 个主要行为方向构成的子空间中，逐日计算截面谱有效秩、最强公共方向占比、截面离散度以及全市场行为中心相对长期常态的偏离。PCA 在这里仅用于事后降维分析和可视化，不参与 WPE 训练，也不改变原始 128 维指纹。

图表 11 展示了 WPE 主要行为空间的信息容量与全市场状态变化。其中，谱有效秩衡量当日截面信息在前 20 个主要行为方向之间的分布是否均衡。2020 年以来，前 20 维主要行为空间的谱有效秩中位数约为 15.0，10%-90%分位区间约为 12.3-16.9；当日最强公共方向的方差占比中位数约为 19%。这表明，在多数时期，市场行为并未退化为由单一方向主导，而是由多个不同的行为方向共同构成。

这些指标还会随市场状态发生明显变化。在 2020 年初、2024 年 2 月和 2024 年 9 月末等特殊时期，谱有效秩阶段性下降、最强公共方向占比上升，说明更多股票受到相近交易机制的共同驱动，市场行为趋于同质化；进入常态阶段后，谱有效秩重新回升，截面结构再次展开，股票之间的行为差异恢复。由此可见，指纹不仅能够描述个股在某一时刻的行为特征，也能够刻画全市场交易行为由分化走向集中、再由集中恢复分化的过程。

图表11：指纹主要行为空间的信息容量与全市场状态变化



资料来源：Wind，国盛证券研究所


3.5.2 指纹并非传统风格与价量指标的简单重编码

为了检验指纹是否只是传统风险因子、行业分类和普通日线技术指标的重新组合，我们分别使用 Barra 风格、行业哑变量和 OHLCV 技术指标，对 128 维 WPE 指纹进行截面拟合，并考察这些传统变量对指纹差异的解释程度。

图表 12 结果显示，全变量模型在不同年份对 WPE 指纹截面差异的整体解释率约为 12%-22%。其中，Barra 风格因子的平均解释率约为 10.9%，行业变量约为 2.7%，普通 OHLCV 技术指标约为 8.8%。即使将上述变量合并，仍有约八成的指纹截面差异无法由传统变量解释。这说明指纹向量包含了大量超出传统风格、行业归属和简单价量指标的信息，其

表征并不是对现有风险因子的机械复刻。这一结果并不意味着指纹与市值、波动率或流动性完全无关，指纹能够识别市值、波动率或流动性背后的交易结构；但同一传统风格区域内仍包含大量不同指纹状态。

图表12：传统风格、行业与日线技术指标对指纹的历史解释率



资料来源：Wind，国盛证券研究所

3.5.3 指纹具有股票层面的时间连续性


如果 WPE 指纹主要由随机噪声构成，那么同一股票在不同日期之间的指纹相似度，不应显著高于任意两只股票之间的相似度。为此，我们分别计算同一股票跨 1、5、10 和 20 个交易日的指纹余弦相似度，并与同期随机股票配对结果进行比较。

图表 13 检验结果显示，同一股票相隔 1、5、10 和 20 个交易日的平均指纹相似度分别约为 0.524、0.398、0.339 和 0.252，而随机股票之间仅约为 0.077、0.068、0.066 和 0.052。虽然随着时间间隔拉长，同一股票的指纹相似度逐步下降，但在各个时间尺度上均明显高于随机对照。这表明 WPE 记录的并非每日独立的短期扰动，而是具有一定持续性的股票行为状态。

这种“短期稳定、长期可迁移”的特征符合真实交易行为的演化规律。股票的参与者构成、订单习惯和流动性供给方式通常不会在一天之内完全重置，因此指纹具有明显的短期延续性；与此同时，随着行情变化、资金迁移和价格位置调整，交易行为又会逐渐转变，因而跨期相似度随时间下降。

这一结果也为下游模型使用最近 20 个交易日的指纹序列提供了实证依据。下游模型所处理的不是 20 个彼此独立的截面特征，而是一条具有延续、变化和状态转换特征的行为轨迹。模型可以据此区分稳定持续的行为模式、正在形成的新状态，以及已经发生明显变化的旧状态。

图表 13: 同一股票与随机股票的跨期指纹相似度



资料来源: Wind, 国盛证券研究所

3.5.4 指纹距离具有明确的经济含义


在确认指纹向量具有稳定的信息结构和时间连续性后, 我们进一步检验指纹空间中的几何距离是否具有经济含义。具体而言, 在每个截面上按照股票之间的指纹距离进行分组, 比较行为指纹由近及远时, 两只股票未来收益差异和收益方向一致性的变化。

图表 14、图表 15 的结果呈现出较为清晰的单调关系: 以 2022/04/25、2024/02/05、2024/09/24、2026/05/15 这几个相对极端的行情日期计算, 从指纹距离最近组到最远组, 两只股票未来收益的绝对差由约 8.17% 逐步扩大至 11.33%, 未来收益同方向比例则由 84.49% 下降至 73.33%。这说明, WPE 距离越近的股票, 未来一段时间的收益状态通常越相似; 指纹距离越远, 其后续表现的分化程度也越高。

这里的结论并不是说 WPE 距离本身可以直接决定未来涨跌方向, 而是说明指纹空间具有有效的局部结构。相近位置的股票往往受到相似的资金参与、订单供给和交易行为机制驱动, 因此其后续收益状态更容易表现出一致性; 距离较远的股票则处于不同的行为状态, 其未来表现也更容易发生分化。

这一特征进一步解释了 WPE 指纹对选股模型的价值。传统行业和风格分类主要回答两只股票在静态属性上是否相似, 而 WPE 能够进一步判断它们在当前时点是否由相近的微观交易机制所驱动。下游 CDE 由此可以在连续行为空间中寻找历史类比, 识别相似股票内部的相对强弱, 并将传统分类难以覆盖的微观行为差异转化为选股信息。

图表14: 指纹距离与未来收益绝对差的单调关系



资料来源: Wind, 国盛证券研究所

图表15: 指纹距离与未来收益同方向比例的单调关系



资料来源: Wind, 国盛证券研究所

3.5.5 固定股票群体可以识别真实的行为迁移

前文表明, WPE 指纹既具有时间连续性, 其空间距离也包含一定的经济信息。在此基础上, 我们进一步考察: 对于同一批股票, 指纹能否持续记录其行为状态在市场事件中的变化。

如果每天重新筛选股票, 指纹位置的变化可能同时受到股票名单更替和真实行为变化的影响。为排除这一干扰, 我们在事件开始时确定研究群体, 并在后续日期持续跟踪同一批股票。2024 年 2 月流动性冲击中, 我们固定跟踪 2024 年 1 月初确定的小微盘股票; 2026 年 4-6 月科技行情中, 则固定跟踪 2026 年 4 月初确定的科技股票。不同日期均投影至统一的历史主成分坐标, 并保持相同的横纵坐标范围, 以保证轨迹具有可比性。

2024 年 2 月, 小微盘股票的行为指纹在流动性冲击期间出现明显偏移。相对于 2024 年 1 月 3 日的初始状态, 2 月 5 日群体中心在二维指纹空间中的移动距离达到 3.07, 说明同一批小微盘股票的交易行为已经明显偏离事件前水平。随后, 群体中心距离在 2 月 8 日下降至 1.72, 并在 2 月 29 日进一步下降至 0.27, 呈现出“快速偏离、逐步回归”的变化过程。该轨迹与小微盘流动性压力集中释放、随后市场逐渐修复的过程基本一致。

2026 年 4-6 月, 科技股票则呈现出更加持续的行为迁移。相对于 4 月 1 日的初始状态, 科技股票群体中心在 4 月 30 日移动 0.50, 5 月 29 日进一步扩大至 1.86, 表明科技股票的交易行为在行情发展过程中持续发生变化。至 6 月 30 日, 群体中心距离虽然回落至 1.22, 但仍明显偏离初始位置。这说明科技行情并非仅表现为某个交易日的价格上涨, 而是伴随着资金参与方式、交易活跃度和订单结构的持续调整; 即使行情强度有所减弱, 相关行为状态也没有立即回到起点。


上述结果表明, WPE 不仅能够描述某一时点股票之间的行为差异, 还能够跟踪固定股票群体的状态演化。不同市场事件会形成不同的迁移轨迹: 短期流动性冲击通常表现为行为状态快速偏离并逐步修复, 而持续性行情则可能表现为行为状态不断强化并在较长时间内维持。需要说明的是, 二维轨迹主要用于直观展示群体状态的变化方向与幅度, 并不直接代表风险大小或未来收益方向, 其核心意义在于识别行为状态的形成、强化和消退过程。

图表16: 2024 年 2 月流动性冲击中的小微盘股票指纹迁移



资料来源: Wind, 国盛证券研究所

图表17: 2026 年 4-6 月科技股票指纹迁移



资料来源: Wind, 国盛证券研究所

3.5.6 小结

综合上述检验, WPE 指纹的价值主要体现在四个方面:

- (1) 主要行为空间在长期内保持多方向结构, 并能够反映市场行为的集中与分化;
- (2) 大部分指纹差异无法由传统风格、行业和普通价量指标解释, 表明其包含相对独立的微观行为信息;
- (3) 指纹既具有股票层面的时间连续性, 也形成了具有经济意义的距离结构;
- (4) 固定股票群体在不同市场事件中呈现出清晰且具有差异的迁移轨迹, 说明 WPE 能够持续记录交易行为的形成、强化与消退。

这些性质共同构成了 WPE 指纹作为下游时序选股模型输入的基础。

四、量价指纹的端到端应用再探

4.1 传统机器学习模型的挑战

2026 年以来，市场风格变化较大，传统机器学习模型面临巨大挑战。机器学习因子的失效大致表现为两种不同形式。第一类模型在 4-6 月直接发生方向反转：历史上有效的低波动、低流动性、规模或动量偏好，在市场风格切换后转为负贡献，导致 IC 下降、十分组倒挂以及多头组合回撤。这类模型的问题在于，过去较高的 IC 中混入了大量阶段性风格收益，一旦风格价格反转，模型排序本身也会失效。第二类模型并未出现明显的全市场排序崩溃，十分组仍然较为单调，但指数增强表现不理想。这是因为全市场十分组同时包含了跨市值、跨波动率、跨流动性等不同股票群体之间的收益差异，而指数增强主要依赖基准成分股内部的相对选股能力。一个模型可能擅长判断“哪类股票整体更好”，却不能有效判断“同一指数或相近风格内部哪只股票更好”。当行业、风格和个股权重约束压缩了跨群体收益后，剩余信号不足以覆盖交易成本与约束代价，于是出现十分组单调但指增无效的现象。


以一个因子组合模型为例，在国盛金工前期两篇报告《基于订单聚集现象的高频量价因子研究》和《基于流动性冲击事件的逐笔羊群效应因子——“高频数据+离散化”理念的具体实践》中，我们分别基于“订单聚集”的时间区间、“逐笔数据层面流动性冲击”的时间点，挖掘微观量价特征，各生成了一簇有效因子。我们使用这两个因子簇的 180 个日度因子加 OHLCV 价格序列，端到端训练了一个因子组合模型，该模型自 2022 年以来表现非常稳定，周度 RankIC 均值为 0.106，年化 RankICIR 为 6.83，全市场 10 分组多空对冲的年化收益为 108.48%，年化波动为 17.22%，信息比率为 6.30，周度胜率为 79.74%，最大回撤为 9.61%。图表 18、图表 19 分别展示了该因子的 10 分组净值走势、10 分组超额净值走势，图表 20 报告了该因子的分年度表现。

图表18: 端到端因子 10 分组净值走势



资料来源: Wind, 通联数据, 国盛证券研究所

图表19: 端到端因子 10 分组超额净值走势



资料来源: Wind, 通联数据, 国盛证券研究所

图表20: 端到端因子分年度表现


年份	年化收益率			分组 1 对冲分组 10 绩效指标			
	分组 1	分组 10	分组 1 对冲分组 10	年化波动	信息比率	周度胜率	最大回撤
2022	15.24%	-53.38%	144.97%	14.93%	9.70	82.00%	-4.30%
2023	20.37%	-28.26%	65.56%	10.31%	6.36	82.00%	-2.31%
2024	24.62%	-44.27%	122.11%	25.28%	4.83	75.00%	-9.61%
2025	81.02%	-22.86%	131.39%	11.57%	11.36	83.02%	-1.75%
2026(截至 07/17)	-4.00%	-19.38%	17.81%	20.50%	0.87	74.07%	-9.61%
全历史	28.72%	-39.02%	108.48%	17.22%	6.30	79.74%	-9.61%

资料来源: Wind, 通联数据, 国盛证券研究所

我们使用该端到端训练出来的因子, 构建中证 1000 指数增强组合, 约束条件为: (1) 指数成分股权重不低于 85%; (2) 中信一级行业权重偏离不超过 1%; (3) 个股权重偏离不超过 0.5%; (4) Barra 风格偏离不超过 0.5 倍标准差; (5) 换手率每期单边不超过 10%。组合进行周度调仓, 按印花税 0.05% (卖出单边) + 交易费 0.1% (双边) 扣除手续费。

2022/01/04-2026/07/17, 中证 1000 指数增强组合的年化收益为 13.64%, 相对中证 1000 指数的超额年化收益为 16.74%, 跟踪误差 6.40%, 信息比率为 2.62, 月度胜率为 74.55%, 月度最大回撤为 6.04%。尽管该因子 2026 年十分组也比较单调, 但从指增表现上来看, 截至 2026 年 7 月 17 日, 今年模型超额收益仅为 4.72%, 超额净值自 3 月开始长时间没有明显提升, 6 月开始甚至有一段较长时间的持续回落。

图表21: 端到端因子的中证 1000 指数增强组合净值



资料来源: Wind, 通联数据, 国盛证券研究所

上述现象是很多机器学习模型在 2026 年面临的真实处境: 2026 年以来市场风格急剧反转, 导致模型在中证 1000 成分股内部的微观选股能力发生退化。具体而言, 该端到端因子此前在成分股内部所展现的区分效果, 历史上可能依赖了与特定风格暴露相关的阶段性收益, 而非纯粹独立的个股选择信号。当市场风格发生剧烈切换, 上半年科技成长极致演绎, 这些隐含在微观量价信号中的风格 Beta 收益随之消退。个股层面的真实 Alpha 本就薄弱, 在此基础上叠加多重约束条件, 模型自然无法充分发挥。

4.2 兼顾市场风格变化的指纹端到端模型

鉴于普通机器学习模型难以应对 2026 年行情变化带来的指数增强组合表现不佳的问题，我们在指纹下游端到端模型 CDE 上做了一次根本性的架构权衡：我们暂时不追求历史 IC 最高，而是追求收益来源可分解、可归因、可控制。具体来说，模型在训练时同时学习两件事——什么让这只股票和其他股票不同，什么让它和一批股票同涨同跌。训练完成后，我们只部署前者，不部署后者。不是因为后者不存在或不重要，而是因为“事后能解释多少”和“事前能预测多少”是两回事。共同风格对每日截面收益的解释力可以非常强，但它的方向会随市场状态变化——同一个高波动结构，风险偏好上升时被奖励，风格瓦解时被惩罚。方向不确定的收益，我们不放进组合里。

这样，在将该因子加入我们现有的指增组合后，组合优化层本身就存在行业和风格的主动暴露约束，因子中残存的风格偏离会被进一步压缩，而行为选股部分会穿过约束保留下来。因子自身已经做了一轮 Alpha/Beta 分离，组合层再做第二轮风险控制，两层叠加使得最终的主动收益来源更干净、对风格方向的依赖更低。相比于一个 IC 可能更高但风格嵌入更深的因子，这种设计在风格切换期更不容易出现因子层和组合层“押错同一种风格”的叠加风险，为指增组合提供了一层更稳定的选股增量。

CDE PureAlpha 的目标是将 WPE 形成的个股行为指纹与同期日线价量状态结合，在 20 个交易日的时序窗口内识别股票当前所处的行为-价格联合状态。模型训练时同时设置 Alpha 与 Beta 两类表达空间：AlphaHead 学习能够仅依据历史信息稳定输出的个股排序，BetaHead 则用于识别训练样本中的截面共同收益方向。正式验证和部署时只使用 AlphaHead 输出，因此最终因子不依赖预测时点之后才能确认的共同收益方向。

4.2.1 CDE 模型结构

对于股票 i 在交易日 d ，WPE 提供 128 维行为指纹：

$$z_{i,d} \in R^{128}$$

日线模块提供 6 维价量状态：

$$p_{i,d} \in R^6$$

当前模型没有分别使用两套 GRU，也没有使用复杂的跨模态注意力，而是在每个交易日直接按特征维拼接：

$$x_{i,d} = [z_{i,d}; p_{i,d}] \in R^{134}$$

最近 20 个交易日形成：

$$X_{i,t} = [x_{i,t-19}, \dots, x_{i,t}] \in R^{20 \times 134}$$


这种融合方式的含义是：模型不是先分别判断“行为信号”和“价格信号”，再将两个预测结果相加，而是从最开始就学习二者的联合状态。例如，同样的大资金流入发生在上涨初期、高位加速或深度回撤后，其未来含义可能不同。将 WPE 与价量逐日对齐后共同输入 GRU，使模型能够学习行为状态、价格位置、时间演化的交互关系。

拼接后的 20 日序列进入单层 GRU：

$$h_{i,t} = GRU(X_{i,t})_{last}$$

其中 $h_{i,t} \in R^{64}$ ，模型取最后一个隐藏状态作为股票最近 20 日综合状态摘要，既包含了行为指纹所描述的交易机制演化，也包含了价量所呈现的价格背景。

图表22: CDE PureAlpha 的模型架构



资料来源：国盛证券研究所绘制

共享状态 $h_{i,t}$ 之后，模型分出 AlphaHead、BetaHead 和 LambdaHead。三个分支共享同一个时序表示，但在训练过程中承担不同职责：

（1）AlphaHead: 可直接部署的个股排序

AlphaHead 的结构为：

$$\text{LayerNorm} \rightarrow \text{Linear}(64,32) \rightarrow \text{GELU} \rightarrow \text{Linear}(32,1)$$

其输出为标量：

$$\alpha_{i,t} = f_{\alpha}(h_{i,t}) \in \mathbb{R}$$

$\alpha_{i,t}$ 是验证和正式部署时使用的股票排序分数，目标是学习能够从个股历史行为与价量状态中稳定复现的未来相对收益规律。AlphaHead 最后一层使用较小的初始化增益，使初始输出接近 0，然后在训练过程中逐步学习偏离零的方向。

（2）BetaHead: 识别截面共同收益方向

BetaHead 与 AlphaHead 使用相同的网络结构：

$$\text{LayerNorm} \rightarrow \text{Linear}(64,32) \rightarrow \text{GELU} \rightarrow \text{Linear}(32,K)$$

其中 $K = 8$ ，对股票 i 在交易日 t 输出：

$$\tilde{\beta}_{i,t} = \text{BetaHead}(h_{i,t}) \in \mathbb{R}^K$$

模型随后对每一根 Beta 轴进行当日截面标准化：

$$\beta_{i,t,k} = \frac{\tilde{\beta}_{i,t,k} - \text{mean}_j(\tilde{\beta}_{j,t,k})}{\text{std}_j(\tilde{\beta}_{j,t,k}) + \varepsilon}$$

因此，每根 Beta 轴在当日截面上均值约为 0、标准差约为 1。经过这一处理后，不同 Beta 轴的数值尺度保持一致，后续收益解释不会因为某根轴天然幅度更大而被其支配。

这里的 Beta 不是预先给定的 Barra 市值、动量、波动率或流动性因子，也不是一个固定不变的常数。它是模型根据股票最近 20 日的 WPE 行为指纹与价量状态，动态生成的截面暴露：

$$\beta_{i,t} = f_{\beta}(h_{i,t})$$

同一只股票的 Beta 暴露可以随时间变化；同一根 Beta 轴在不同训练轮次中也不一定具有完全相同的经济命名。它更准确的含义是：模型从全市场股票的行为与价量状态中，寻找若干能够共同解释当期截面收益差异的方向。

例如，某一根 Beta 轴可能同时对高换手、高波动、高市场 Beta 和近期强势股票赋予较高暴露；另一根轴可能更多地区分低流动性、小市值和短期反转股票。它们未必分别对应单一的传统风格，更可能是多个传统特征与行为模式形成的联合方向：

$$\beta_k \approx a_1 \cdot \text{Size} + a_2 \cdot \text{Volatility} + a_3 \cdot \text{Liquidity} + a_4 \cdot \text{Momentum} + a_5 \cdot \text{BehavioralPattern}$$

因此，BetaHead 学习的不是“第 1 根一定是市值、第 2 根一定是动量”这种人工定义，而是由训练数据内生确定的共同收益坐标系。传统 Barra 风格可以用于事后解释这些坐标，但不是模型生成 Beta 时的输入标签。

(3) LambdaHead: 构造训练期的截面收益基准

LambdaHead 同样读取共享状态 $h_{i,t}$ ，为每只股票在每根风格轴上生成一个截面权重原始值。将当日全市场股票的权重归一化以后，可以形成第 k 根风格轴对应的代表性股票组合：

$$w_{i,t,k} \geq 0, \quad \sum_i w_{i,t,k} = 1$$

训练时，模型使用未来收益的截面排名标准分：

$$y_{i,t}^{\text{rank}} = \text{RankZScore}(r_{i,t+1:t+6})$$

计算每根 Beta 轴在该训练样本上的实现收益：

$$\lambda_{t,k}^{\text{true}} = \sum_i w_{i,t,k} y_{i,t}^{\text{rank}}$$

每只股票在每种风格上的权重 $w_{i,t,k}$ 和对这种风格的暴露 $\beta_{i,t,k}$ 不是同一个东西。可以类比指数：指数权重决定如何用成分股收益计算指数收益，Beta 则表示指数涨跌时，每只股票通常跟随多少。股票的指数权重可能很小，但 Beta 依然可以很高。CDE 中，LambdaHead 的 weight 负责从股票收益中提取几个共同收益，BetaHead 则刻画每只股票对这些共同收益的暴露。

4.2.2 CDE 训练与部署

CDE 模型采用五年训练+验证（早期数据可能不足五年），一年测试的滚动划分。训练阶段，模型将 AlphaHead 输出与 Beta 共同收益部分相加：

$$\hat{y}_{i,t}^{\text{train}} = \alpha_{i,t} + \frac{1}{\sqrt{K}} \sum_{k=1}^K \beta_{i,t,k} \lambda_{t,k}^{\text{true}}$$

也可以写成向量形式：

$$\hat{y}_{i,t}^{\text{train}} = \alpha_{i,t} + \frac{\beta_{i,t}^T \lambda_t^{\text{true}}}{\sqrt{K}}$$

训练预测在每日截面上进行标准化：

$$\tilde{y}_{i,t}^{\text{train}} = \text{ZScore}_{CS}(\hat{y}_{i,t}^{\text{train}})$$

然后与未来收益标签进行 MSE 比较：

$$\mathcal{L}_{\text{return}} = \text{MSE}(\hat{\mathbf{y}}_t^{\text{train}}, \mathbf{y}_t)$$

该损失并不要求模型精确预测未来收益的绝对涨跌幅，而是要求模型在每日完整股票截面上给出正确的相对排序和相对强弱。采用截面标准化以后，损失更关注股票之间的排序结构，减少不同交易日市场整体涨跌幅和收益离散度差异对训练的干扰。

从训练目标看，未来收益被分成两部分：

$$y_{i,t} \approx \underbrace{\alpha_{i,t}}_{\text{可直接部署的个股分数}} + \underbrace{\frac{1}{\sqrt{K}} \beta_{i,t}^\top \lambda_t^{\text{true}}}_{\text{训练期共同收益解释}} + \epsilon_{i,t}$$

Beta 分支帮助模型解释当日收益中具有截面共性的部分，AlphaHead 则承担剩余的、能够仅根据个股历史状态直接输出的预测任务。

训练阶段可以使用未来收益识别当期共同收益结构，但这些未来收益在真实预测时不可获得，并且我们实际实验下来发现，不同 Beta 轴对应的风格收益在样本外难以预测。因此，正式部署路径目前只依赖预测时点已经观测到的信息。当前 PureAlpha 模型最终输出为：

$$\text{Score}_{i,t} = \alpha_{i,t}$$

也就是：

$$\text{Score}_{i,t} = \text{AlphaHead} \left(\text{GRU}([z_{i,t-19:t}; p_{i,t-19:t}])_{\text{last}} \right)$$

4.2.3 Alpha 与 Beta 的分工逻辑

如果模型只有一个 AlphaHead，并直接使用原始未来收益监督，那么所有能够降低训练损失的信息都会被写入同一个分数：

$$\alpha_{i,t}^{\text{single}} \approx E[r_{i,t+1:t+6} | X_{i,t}]$$

这个条件期望既可能包含真正的个股行为 Alpha，也可能包含训练期内长期有效的风格收益。例如，如果低波动、小市值或某类高流动性股票在训练期的大多数阶段具有正收益贡献，单头模型会自然地把这些规律写入 Alpha。模型并不知道研究者希望将其称为“Alpha”还是“Beta”，它只知道这些特征能够降低预测误差。

加入 BetaHead 以后，模型获得了一个显式描述截面共同收益结构的通道。对于一批在行为和价量状态上相近、未来收益又呈现共同变化的股票，模型可以通过 $\beta_{i,t}^\top \lambda_t^{\text{true}}$ 解释其共同收益，而不必全部塞入 AlphaHead。这种设计的核心价值不是保证 Alpha 与所有传统风格严格正交，而是让网络在训练阶段具备区分“个股可复现规律”、“股票群体截面共同变化”这两类信息的能力。

图表23: CDE 对个股收益的分解

信息类型	典型表现	主要承载分支
个股可复现规律	相似行为状态下，个股未来相对表现长期稳定	AlphaHead
截面共同变化	一批具有相似状态的股票在某段时期共同上涨或下跌	BetaHead
无法稳定解释部分	偶发事件、噪声和未观测信息	残差

资料来源：国盛证券研究所绘制

需要特别说明的是，当前模型并没有在数学上强制：

$$\text{corr}(\alpha, \beta_k) = 0$$

也没有要求 Alpha 对 Barra 市值、动量、波动率、流动性等传统风格的暴露严格为零。因此, AlphaHead 虽然是正式部署分数, 并且我们也称其为 PureAlpha, 但这是相对的纯净, 不等于传统风险模型意义上的“完全风格中性残差”。这是因为 Alpha 和 Beta 共享同一个 GRU 状态:

$$h_{i,t} = \text{GRU}(X_{i,t})_{\text{last}}$$

AlphaHead 和 BetaHead 只是从同一个状态 $h_{i,t}$ 中读取不同的输出, 只要某种行为模式既具有长期稳定的收益关系, 又在部分阶段表现为一批股票的共同运动, 两个分支就可能同时使用这一信息。更一般地, 真实收益可以写成:

$$r_{i,t} = \alpha_{i,t}^{\text{idio}} + \beta_{i,t}^T \bar{\lambda} + \beta_{i,t}^T \Delta \lambda_t + \epsilon_{i,t}$$

其中:

- $\alpha_{i,t}^{\text{idio}}$ 是控制共同风格后仍然存在的个股特质收益;
- $\bar{\lambda}$ 是某些共同方向在训练期的长期平均收益;
- $\Delta \lambda_t$ 是共同方向在特定阶段相对长期均值的偏离。

当 AlphaHead 直接从历史状态学习稳定收益规律时, 它可能吸收前两项中的一部分:

$$\alpha_{i,t} \approx \alpha_{i,t}^{\text{idio}} + \beta_{i,t}^T \bar{\lambda}$$

例如, 模型可能发现“低波动、低流动性并伴随特定资金流入行为”的股票, 在大多数训练阶段具有较高的未来收益。虽然这一规律在截面上表现为一组股票的共同风格暴露, 但由于其训练期平均收益长期为正, AlphaHead 仍会把这部分长期收益规律吸收进最终分数; BetaHead 则主要负责描述这批股票在特定阶段同步上涨或下跌的共同变化。因此, 同一种低波动或流动性相关信息可能同时出现在 Alpha 和 Beta 中: 进入 Alpha 的是其长期平均有效部分, 进入 Beta 的是其阶段性共同波动部分。这样设计不是实现绝对的风格中性, 而是在收益预测能力、结构可解释性与指增风险约束之间取得平衡。这种设计主要具有以下几点优势:

(1) **避免把所有共同收益都交给短期方向判断。**共同方向是否存在、个股对其暴露多大, 与下一阶段该方向涨跌, 并不是同一个问题。AlphaHead 负责学习较稳定的条件均值, BetaHead 负责为训练期收益分解提供公共坐标, 使模型不必依赖对每一次风格切换的准确预测。

(2) **保留有效的长期收益信息。**如果对全部风格暴露做严格零中性化, 模型只能学习很薄的风格内差异; 允许 AlphaHead 吸收 $\beta_{i,t}^T \bar{\lambda}$, 可以保留训练期长期、重复出现的风险溢价和行为收益规律, 通常有助于维持原始 IC 和多头收益厚度。

(3) **形成结构化的训练约束。**BetaHead 为截面共同变化提供独立表达通道, 降低单一 Alpha 输出同时承担个股差异和全部共同行情解释的压力。即使正式部署只使用 AlphaHead, 训练中的分支结构仍有助于整理共享表示中的信息分工。

(4) **更符合指数增强的实际约束。**指增组合通常控制的是相对基准的主动风格暴露, 而不是要求所有股票分数对每个风格严格为零。只要暴露处于预算内, 少量长期风格溢价可以作为收益来源, 同时由组合层约束其相对基准偏离。

4.3 指纹 PureAlpha 单因子及指增效果检验

如上文所述, CDE 在训练时分离了 AlphaHead 和 BetaHead, 部署时只使用 AlphaHead 输出的 PureAlpha 因子。这个设计的有效性需要通过实证来验证——AlphaHead 剥离掉方向时变的共同收益之后, 是否真的在指增框架下比原始端到端因子更稳定。同时, 考

考虑到 PureAlpha 因子可能保留的选股信息与原有端到端因子存在互补，将二者合成或许能兼顾两方面的优势。


我们首先对指纹 PureAlpha 因子进行了单因子测试，回测区间为 2021/01/04-2026/07/17，以全体 A 股为样本，周度换仓，暂时不考虑交易费用，以 vwap 买入和卖出。该因子周度 RankIC 均值为 0.078，年化 RankICIR 为 5.66，全市场 10 分组多空对冲的年化收益为 76.94%，年化波动为 12.79%，信息比率为 6.02，周度胜率为 76.41%，最大回撤为 10.36%。图表 24、图表 25 展示了指纹 PureAlpha 因子的 10 分组净值走势、10 分组超额净值走势，图表 26 报告了指纹 PureAlpha 因子的分年度表现。

图表24: 指纹 PureAlpha 因子 10 分组净值走势



资料来源: Wind, 通联数据, 国盛证券研究所

图表25: 指纹 PureAlpha 因子 10 分组超额净值走势



资料来源: Wind, 通联数据, 国盛证券研究所

图表26: 指纹 PureAlpha 因子分年度表现

年份	年化收益率			分组 1 对冲分组 10 绩效指标			
	分组 1	分组 10	分组 1 对冲分组 10	年化波动	信息比率	周度胜率	最大回撤
2021	37.11%	6.18%	28.64%	10.52%	2.72	57.69%	-3.50%
2022	2.92%	-39.63%	70.17%	8.69%	8.07	82.00%	-1.96%
2023	26.78%	-24.38%	66.91%	9.65%	6.93	80.00%	-4.36%
2024	21.76%	-35.29%	89.49%	18.26%	4.90	75.00%	-10.36%
2025	73.27%	-23.17%	124.64%	10.36%	12.03	88.68%	-2.07%
2026(截至 07/17)	-2.44%	-26.87%	33.94%	17.71%	1.92	74.07%	-7.27%
全历史	27.76%	-27.84%	76.94%	12.79%	6.02	76.41%	-10.36%

资料来源: Wind, 通联数据, 国盛证券研究所


从单因子测试结果看，PureAlpha 因子的全市场多空年化收益为 76.94%，低于端到端因子的 108.48%；RankIC 均值 0.078 也略低于后者的 0.106。这一差距在预期之内——PureAlpha 在训练中剥离了方向时变的共同收益成分，仅保留 AlphaHead 输出，相当于主动放弃了部分训练期内稳定的风格红利和跨群体区分度，因此在全市场分组测试中自然会显得“弱一些”。但全市场测试的强弱并非我们最关心的维度，关键在于指增框架下的实际效果：被剥离掉的 Beta 收益在组合优化层受到严格约束，本就难以充分兑现；而 AlphaHead 保留的个股选股信号反而可能更干净地穿过行业、市值和个股权重限制，转化为真实的超额收益。

基于这一判断，我们将前文的端到端因子与指纹 PureAlpha 因子按 8:2 的比例加权合成复合因子，试图在保留端到端因子选股强度的同时，引入 PureAlpha 在约束条件下更稳定的选股贡献，并进一步应用于中证 1000 指数增强组合中进行回测验证。约束条件与 4.1 节保持一致：（1）指数成分股权重不低于 85%；（2）中信一级行业权重偏离不超过 1%；（3）个股权重偏离不超过 0.5%；（4）Barra 风格偏离不超过 0.5 倍标准差；（5）

换手率每期单边不超过 10%。组合周度进行调仓，按印花税 0.05%（卖出单边）+ 交易费 0.1%（双边）扣除手续费。

2022/01/04-2026/07/17, 中证 1000 指数增强组合的年化收益为 14.05%, 相对中证 1000 指数的超额年化收益为 17.30%, 跟踪误差 6.13%, 信息比率为 2.82, 月度胜率为 78.18%, 月度最大回撤为 3.17%。可以看到, 在叠加上我们的指纹 PureAlpha 因子后, 中证 1000 指增组合在各个指标上均有明显提升。

图表27: 80%端到端+20%指纹 PureAlpha 因子的中证 1000 指数增强组合净值



资料来源: Wind, 通联数据, 国盛证券研究所

图表28: 不同因子对应的中证 1000 指数增强组合绩效指标对比

	100%端到端因子	80%端到端因子+20%指纹 PureAlpha 因子
年化收益	13.64%	14.05%
超额年化收益	16.74%	17.30%
跟踪误差	6.40%	6.13%
信息比率	2.62	2.82
月度胜率	74.55%	78.18%
月度最大回撤	-6.04%	-3.17%
2026 年超额收益 (截至 07/17)	4.72%	8.26%

资料来源: Wind, 通联数据, 国盛证券研究所

若重点关注 2026 年的表现, 截至 2026/07/17, 复合因子指增组合的超额收益为 8.26%, 相比纯端到端因子的 4.72% 提升了约 3.5 个百分点, 且超额净值在 3 月至 6 月期间保持了平稳上行, 没有再出现长时间的停滞和回落。这说明 **PureAlpha** 因子的加入确实缓解了端到端因子在风格切换期的微观选股退化问题, 验证了 Alpha/Beta 分离设计在指增约束下的实际价值。

五、进一步讨论

5.1 指纹 PureAlpha 因子的跨指数增益

为进一步验证复合因子的适用边界与稳健性，我们在中证 500 和沪深 300 两个基准上进行了相同的测试。前者代表中盘风格，成分股覆盖了中证 1000 以外的中等市值股票，行业分布相对均衡；后者代表大盘蓝筹风格，成分股权重更为集中，且与主流指数增强策略的资金容量直接相关。通过在不同市值层级和指数特征上的回测，可以观察复合因子在风格约束收紧、个股权重差异缩小以及行业分布变化下的表现是否仍然稳定。

中证 500 指增组合的约束条件为：（1）指数成分股权重不低于 85%；（2）中信一级行业权重偏离不超过 1%；（3）个股权重偏离不超过 0.5%；（4）Barra 风格偏离不超过 0.5 倍标准差；（5）换手率每期单边不超过 10%。组合进行周度调仓，按印花税 0.05%（卖出单边）+交易费 0.1%（双边）扣除手续费。

图表 29-图表 31 分别展示了 100%端到端因子、80%端到端因子+20%指纹 PureAlpha 因子两种情况下的中证 500 指增组合净值曲线及绩效指标对比。

从回测结果看，加入 20%的指纹 PureAlpha 因子后，中证 500 指增组合的收益与风险收益比均有所改善。组合年化收益由 13.90%提高至 14.50%，超额年化收益由 13.34%提高至 13.98%；尽管跟踪误差由 5.44%小幅上升至 5.50%，信息比率仍由 2.45 提高至 2.54，说明新增收益足以覆盖主动风险的轻微增加。

组合稳定性也得到改善。月度胜率由 76.36%提高至 78.18%，月度最大回撤由 3.60%收窄至 2.59%。尤其在 2026 年市场风格变化较大的环境中，组合超额收益由 5.11%提高至 9.25%，增幅达到 4.14 个百分点。该结果说明，指纹 PureAlpha 带来的增益并非仅来自长期均值抬升，在原有端到端因子面临风格适应压力时，也能够提供较明显的差异化选股信息。

中证 500 成分股的市值和流动性整体高于中证 1000，个股之间的行为差异相对收敛，同时组合受到较严格的成分股、行业和风格约束。在这一条件下，PureAlpha 仍能提高组合收益、信息比率和月度胜率，表明 WPE 行为指纹并非只在小市值股票中有效。其对资金参与方式、买卖压力和交易结构的刻画，在中盘股票内部同样能够提供传统端到端量价因子尚未完全覆盖的信息。


进一步来看，20%的因子权重并未显著改变组合的整体风险结构，却明显改善了 2026 年的超额收益与回撤表现。这与前文的因子分析相互印证：PureAlpha 既保留了一定的风格内选股能力，也能够根据当前行为—价格状态调整高分股票的风格落点。因此，将其作为现有复合因子的补充，比单独扩大原有端到端因子的暴露更有利于提升组合的信息分散度。

图表29: 100%端到端因子的中证 500 指增组合净值



资料来源: Wind, 通联数据, 国盛证券研究所

图表30: 80%端到端+20%指纹 PureAlpha 因子的中证 500 指增组合净值



资料来源: Wind, 通联数据, 国盛证券研究所

图表31: 不同因子对应的中证 500 指数增强组合绩效指标对比

	100%端到端因子	80%端到端因子+20%指纹 PureAlpha 因子
年化收益	13.90%	14.50%
超额年化收益	13.34%	13.98%
跟踪误差	5.44%	5.50%
信息比率	2.45	2.54
月度胜率	76.36%	78.18%
月度最大回撤	-3.60%	-2.59%
2026 年超额收益 (截至 07/17)	5.11%	9.25%

资料来源: Wind, 通联数据, 国盛证券研究所

沪深 300 指增组合的约束条件同样设定为: (1) 指数成分股权重不低于 85%; (2) 中信一级行业权重偏离不超过 1%; (3) 个股权重偏离不超过 0.5%; (4) Barra 风格偏离不超过 0.5 倍标准差; (5) 换手率每期单边不超过 10%。组合周度进行调仓, 按印花税 0.05% (卖出单边) + 交易费 0.1% (双边) 扣除手续费。

图表 32-图表 34 分别展示了 100%端到端因子、80%端到端因子+20%指纹 PureAlpha 因子两种情况下的沪深 300 指增组合净值曲线及绩效指标对比。


从回测结果看, 指纹 PureAlpha 因子在沪深 300 中的增益弱于中证 500、中证 1000。加入 20%的 PureAlpha 后, 组合年化收益由 8.69%下降至 7.82%, 超额年化收益由 10.84%下降至 9.98%, 信息比率也由 2.29 下降至 2.17。说明在大盘蓝筹股票内部, PureAlpha 提供的新增收益信息相对有限, 替换部分原有端到端因子后, 长期收益水平有所下降。

但组合稳定性出现了一定改善。跟踪误差由 4.72%降至 4.59%, 月度最大回撤由 3.90%收窄至 3.71%, 月度胜率则由 69.09%明显提高至 80.00%。截至 2026 年 7 月 17 日, 今年组合超额收益也由 2.12%提高至 2.51%。因此, PureAlpha 在沪深 300 中的主要作用并非提高长期收益中枢, 而是改善收益分布的一致性, 并在部分风格变化较大的阶段提供一定保护。

这一差异与沪深 300 的股票池特征有关。沪深 300 成分股数量较少、机构覆盖充分、定价效率相对较高, 不同股票之间的行为指纹差异也弱于中证 500 和中证 1000。同时, 指数权重和行业集中度更高, 在成分股比例、个股偏离及风格偏离约束下, PureAlpha 的独


立选股信息难以充分转化为组合权重。将 20% 的原有端到端因子替换为 PureAlpha，可能产生了一定的信息稀释。

图表32: 100%端到端因子的沪深 300 指增组合净值



资料来源: Wind, 通联数据, 国盛证券研究所

图表33: 80%端到端+20%指纹 PureAlpha 因子的沪深 300 指增组合净值



资料来源: Wind, 通联数据, 国盛证券研究所

图表34: 不同因子对应的沪深 300 增强组合绩效指标对比

	100%端到端因子	80%端到端因子+20%指纹 PureAlpha 因子
年化收益	8.69%	7.82%
超额年化收益	10.84%	9.98%
跟踪误差	4.72%	4.59%
信息比率	2.29	2.17
月度胜率	69.09%	80.00%
月度最大回撤	-3.90%	-3.71%
2026 年超额收益 (截至 07/17)	2.12%	2.51%

资料来源: Wind, 通联数据, 国盛证券研究所

综合中证 1000、中证 500 与沪深 300 指数增强组合的测试结果，指纹 PureAlpha 的增量价值具有明显的股票池差异：在中证 1000、中证 500 中能够同时提高收益、信息比率和回撤表现；在沪深 300 中则更多体现为提高月度胜率、降低跟踪误差和改善特殊阶段的表现。

5.2 指纹 PureAlpha 因子的选股能力与风格适应性

指数增强策略对选股因子提出了两个并存且相互制约的要求。其一是风格内选股能力，即因子需要在不同市值区间、不同行业以及不同风险特征的股票内部均保持稳定的排序能力，从而避免因某一风格的阶段性失效而使整体选股结果同步反向；其二是保留一定的风格收益获取能力，由于指数增强组合通常只限制组合相对基准的主动风格偏离，而不会把所有风格敞口严格压缩至零，因子仍需要在合理范围内识别当前更具收益优势的股票群体，以维持足够的原始 IC 和多头收益厚度。

二者存在天然张力。过度依赖风格倾斜，能够在风格持续占优阶段显著提高全市场 IC，但一旦市场发生风格反转，因子的整体排序可能同步失效；而将市值、行业、波动率、流动性等共同信息完全剥离，虽然可以降低风格风险，却容易只留下较薄的风格内 Alpha，使信号难以支撑实际的指增收益。

指纹 PureAlpha 试图在两者之间取得平衡。模型通过 AlphaHead 学习可由个股行为指纹和价量状态稳定解释的收益规律，同时利用 BetaHead 刻画截面共同收益结构，为共享表示提供结构化约束。因此，正式部署的 Alpha 分数既保留个股层面的行为选股信息，也没有在训练阶段被强制处理成完全风格中性的残差。


基于这一设计，下面从两个角度检验 PureAlpha 的信息来源：首先通过市值和行业中性化，考察剔除主要组间差异后因子是否仍具有稳定的风格内选股能力；其次分析因子与 Barra 风格的时序相关性，观察其股票偏好是否能够随市场环境发生变化。前者回答“因子是否具有独立于市值和行业的 Alpha”，后者回答“因子是否在保留选股能力的同时利用了部分条件风格收益”。

5.2.1 市值与行业中性化检验

为了检验指纹 PureAlpha 因子的收益是否主要来自市值和行业倾斜，我们对因子进行了市值和行业中性化，并对中性化后的残差因子进行十分组检验。回测时间段为 2021/01/04-2026/07/17，以全体 A 股为样本，周度换仓，暂时不考虑交易费用，以 vwap 买入和卖出。中性化处理的目的并不是追求一个可以直接部署的最终因子，而是回答一个更基础的问题：PureAlpha 的历史收益究竟主要来自持续偏好某些市值区间和强势行业，还是来自相同市值与行业条件下的个股行为差异。如果中性化后因子显著衰减，说明原始收益更多依赖组间配置；如果中性化后仍保持较好的排序能力，则表明 WPE 指纹包含独立于市值和行业的个股层面信息。


实证结果显示，市值和行业中性化后的 PureAlpha 因子，周度 RankIC 均值为 0.070，年化 RankICIR 为 7.91，10 分组多空对冲的年化收益为 65.11%，年化波动为 8.25%，信息比率为 7.89，周度胜率为 79.93%，最大回撤为 2.40%。图表 35-图表 37 展示了指纹 PureAlpha 因子市值、行业中性化后的 10 分组净值走势、10 分组超额净值走势、多空对冲净值曲线。

图表35：市值、行业中性化后的 PureAlpha 因子 10 分组净值走势




资料来源：Wind，通联数据，国盛证券研究所

图表36：市值、行业中性化后的 PureAlpha 因子 10 分组超额净值走势



资料来源：Wind，通联数据，国盛证券研究所

图表37：市值、行业中性化后的 PureAlpha 因子 10 分组多空对冲净值曲线



资料来源：Wind，通联数据，国盛证券研究所

从十分组结果来看，中性化后的因子仍能在截面上区分未来表现不同的股票。由于市值和行业所带来的主要组间差异已被回归剔除，这种分组差异更多反映同类股票之间的行为状态差异。例如，同处一个行业、具有相近市值特征的股票，仍可能在资金参与结构、主动买卖压力、撤单行为、成交活跃度和价格位置等方面存在明显区别，而 WPE 指纹能够对这些差异进行综合刻画。

较高的 RankICIR 和周度胜率进一步说明，这部分信息并非由少数特殊行情集中贡献，而是在较长测试区间内具有较好的方向一致性。与此同时，多空组合保持较低的年化波动和最大回撤，表明中性化后的收益并不是简单放大个股波动得到的，而是来源于相对稳定的截面排序。当然，由于该测试暂未考虑交易费用，年化多空收益主要用于衡量信号强度和分组区分度，不应直接等同于可实现的组合收益。

这一结果说明，PureAlpha 的有效性不能简单归结为持续偏好小市值股票，或集中配置历史表现较强的行业。即使控制市值和行业暴露，WPE 行为指纹所刻画的交易行为差异仍然能够解释未来收益。这部分不依赖主要组间配置的选股信息，构成了 PureAlpha 应用于指数增强策略的稳健基础。

另一方面，中性化检验并不意味着正式部署时必须将所有风格信息完全剥离。该实验的意义在于确认 PureAlpha 具有独立的风格内选股能力；原始因子是否还保留了有价值的条件风格收益，则需要结合后续 Barra 风格暴露分析进一步判断。前者决定因子在风格切换时能否保持基本有效，后者则决定因子能否在合理风险预算内增加原始 IC 和多头收益厚度。两部分共同构成 PureAlpha 在指数增强组合中的信息增量。

5.2.2 Barra 风格暴露分析

PureAlpha 在市值、行业中性化后仍然有效，证明了其风格内选股能力；而原始因子与 Barra 风格的时序相关性，则进一步揭示了 AlphaHead 如何随市场环境调整股票偏好。二者结合说明，因子的收益既不是单纯来自传统风格暴露，也不是完全剥离风格后的个股残差，而是由风格内选股能力与行为状态所支持的条件风格收益共同构成。图表 38 展示了 PureAlpha 因子与几个典型 Barra 风格的历史相关性序列。


2021-2023 年，因子整体更偏向低波动、低流动性股票，与市场 Beta 的平均相关性接近于零。具体来看，因子与 Beta 的年度平均相关系数分别为 0.029、0.028 和 -0.001；与

Liquidity 的相关系数分别为-0.063、-0.170 和-0.164；与 Volatility 的相关系数分别为-0.165、-0.265 和-0.267。这说明在这一阶段，模型更认可交易结构平稳、资金参与相对温和、短期拥挤程度较低的股票。这种偏好在风险偏好较弱、市场缺乏持续主线的环境中具有一定优势。低波动、低流动性暴露一方面降低了因子对高换手题材和拥挤交易的依赖，另一方面也使其能够从稳定交易结构的持续性中获得收益。因此，2021-2023 年的部分原始 IC 和多头收益，可以理解为风格内选股能力与低波动、低拥挤状态收益的共同贡献，而不是单一传统风格因子的简单复制。

2024 年市场风格切换明显加快，因子的偏好也表现出较强的阶段性变化。年初高分股票一度向高 Beta、交易相对活跃的小市值区域迁移，使因子能够参与市场快速反弹；随后又重新加强对低波动、低流动性结构的偏好。年中阶段，因子的市场弹性有所回升，但仍保留了一定的低波动特征。整体来看，2024 年的 AlphaHead 并未固守单一风格，而是在高 Beta 弹性与低波动防御之间动态调整，为不同市场环境下的选股提供了适应空间。

在 2026 年，这种高弹性偏好表现得更加充分。因子与 Beta、Liquidity 和 Momentum 的平均相关系数分别达到 0.313、0.157 和 0.073，而与 Volatility 的相关性由历史上的约-0.27 至-0.24 收窄至-0.095。与 2024 年相比，2026 年的高 Beta 暴露同时伴随着更明显的正流动性和动量特征，高分股票因而更集中于市场弹性较高、交易活跃度较强的区域。这与 2026 年上半年科技成长和高弹性股票受到市场奖励的行情结构较为一致，使因子能够参与部分科技成长行情，并为指数增强组合带来收益增量。

图表38：指纹 PureAlpha 因子与几类 Barra 风格因子的相关性序列



资料来源：Wind，国盛证券研究所

需要强调的是，这并不意味着模型直接预测了“下一阶段高 Beta 或高流动性风格将会占优”。AlphaHead 学习的是 WPE 行为指纹、价量状态及其 20 日演化与未来收益之间的条件关系。只有当高 Beta、高流动性股票同时呈现模型认可的资金参与、买卖压力、撤单结构和价格位置时，才会获得较高分。Barra 相关性的变化是模型选股结果在传统风格空间中的外部投影，而不是模型直接优化的目标。

因此，PureAlpha 体现的并不是两种静态风格之间的一次性迁移，而是行为条件变化所引起的动态风格落点。2021-2023 年，模型更多受益于低波动、低流动性和低拥挤状态；2024 年则在高 Beta 弹性与低波动防御之间多次切换；2026 年上半年，高 Beta、高流动性和一定动量特征共同获得市场奖励，模型也相应提高了对这些股票的评分。

综上所述，市值、行业中性化后的有效性说明，因子并非完全依靠风格押注；原始因子时变的 Barra 相关性又表明，模型没有因追求严格中性而放弃所有条件风格收益。这种“风格内选股构成稳健基础、行为状态支持的条件风格收益提供收益厚度”的结构，是 PureAlpha 适用于指数增强的重要原因之一。

六、总结

本报告延续前期“量价指纹”的研究框架，进一步完成了从收益相关表征向通用行为表征、从单一收益预测向结构化收益建模的迭代。我们的核心出发点是：市场交易数据不仅包含价格最终如何变化，也包含资金如何参与、订单如何供给、流动性如何变化以及交易行为如何在日内逐步演化。相较于将这些过程压缩为若干人工因子，WPE 尝试建立一套连续的行为坐标，使相似的交易机制在指纹空间中彼此接近，不同的交易状态则得到区分。

在指纹构建方面，WPE 读取每只股票一天 237 分钟、62 项价格和微观交易特征，并将其压缩为 128 维日级指纹。本次迭代不再使用未来股票收益指导指纹预训练，也不再以恢复原始输入为主要目标，而是要求模型根据已经发生的日内序列，预测后续买方压力、撤单压力、委托激进度、大资金参与、波动状态和流动性健康状态。模型预测的是未来行为的条件分布，而非单一点估计，因此不仅描述最可能发生的状态，也保留预测不确定性。五个行为房间、行为一致性约束和房间正交约束，则进一步为 128 维表示建立结构化的信息组织方式。

对 WPE 表征空间的事后分析显示，指纹具有较为稳定的信息结构。历史固定主成分坐标下，前 20 维主要行为空间的截面谱有效秩中位数约为 15.0，表明多数时期市场行为由多个方向共同构成，而非退化为单一公共方向。传统 Barra 风格、行业和普通 OHLCV 技术指标合计只能在线性样本外意义上解释约 12%-22% 的指纹截面差异，说明 WPE 并非传统变量的简单重编码。同一股票跨 1、5、10 和 20 个交易日的指纹相似度持续高于随机股票，说明指纹同时具有短期稳定性和长期迁移性。指纹距离与未来收益差异和方向一致性之间也呈现清晰关系，进一步表明 WPE 空间的几何结构具有经济含义，而不是任意的神经网络坐标。

在下游模型方面，本报告构建了 CDE PureAlpha 框架。模型将最近 20 个交易日的 WPE 指纹与日线价量状态共同输入 GRU，并在共享表示之上设置 AlphaHead 和 BetaHead。BetaHead 在训练阶段为截面共同收益提供独立表达通道，AlphaHead 则输出能够由个股历史状态直接复现的条件收益分数。正式部署仅使用 AlphaHead，从而避免将难以稳定判断方向的共同收益直接加入预测结果。需要强调的是，PureAlpha 并不等同于对所有 Barra 风格严格中性的残差：训练期内长期、重复出现且能够由当前行为状态解释的收益规律，仍可能进入 AlphaHead；BetaHead 的作用是提供结构化分解通道，而不是将所有共同信息机械剥离。

单因子测试表明，2021/01/04-2026/07/17 期间，PureAlpha 的周度 RankIC 均值为 0.078，年化 RankICIR 为 5.66，十分组多空对冲的年化收益为 76.94%，信息比率为 6.02，周度胜率为 76.41%。其全市场 RankIC 和多空收益低于直接预测原始收益的端到端因子，这与模型设计相符：PureAlpha 主动降低了部分方向时变的共同收益对最终分数的影响，因此牺牲了一部分全市场组间区分度。对于指数增强而言，更重要的问题并非全市场 IC 是否达到最高，而是信号能否在行业、个股权重和风格约束下有效转化为组合超额。

市值与行业中性化检验进一步表明，PureAlpha 并非主要依赖市值和行业倾斜。中性化后的因子周度 RankIC 均值仍达到 0.070，年化 RankICIR 为 7.91，十分组多空组合年化收益为 65.11%，信息比率为 7.89，周度胜率为 79.93%，最大回撤为 2.40%。这说明，即使剔除主要组间差异，WPE 所描述的资金参与、买卖压力、订单供给、撤单行为和价格状态，仍能够在相同行业和相近市值的股票内部形成有效排序。这部分风格内选股能力构成了 PureAlpha 应用于指数增强的稳健基础。

与此同时，原始 PureAlpha 与 Barra 风格的相关性并非固定不变。2021-2023 年，模型整体更偏向低波动、低流动性和相对平稳的交易结构；2024 年，模型在高 Beta 弹性与低波动防御之间多次调整；2026 年上半年，高分股票逐步向高 Beta、高流动性和具有一定动量特征的区域迁移，并参与了部分科技成长行情。这并不意味着模型直接预测某个传统风格下一阶段必然占优，而是说明相同的资金流、撤单和价量状态在不同时期会落在不同的 Barra 风格区域。Barra 暴露的变化是行为选股结果在传统风险坐标中的外部投影，而不是模型直接优化的目标。

指数增强回测进一步验证了 PureAlpha 的实际信息增量。将端到端因子与 PureAlpha 按 8:2 组合后，中证 1000 指数增强组合在 2022/01/04-2026/07/17 期间取得 17.30% 的超额年化收益，跟踪误差为 6.13%，信息比率为 2.82，月度胜率为 78.18%，月度最大回撤为 3.17%。2026 年截至 7 月 17 日，复合因子组合的超额收益为 8.26%，较纯端到端因子的 4.72% 提高约 3.5 个百分点，说明行为指纹提供的差异化选股信息能够在市场风格变化较大的阶段改善组合表现。

跨指数结果显示，PureAlpha 的增量价值具有一定股票池差异。在中证 500 中，加入 20% 的 PureAlpha 后，超额年化收益由 13.34% 提高至 13.98%，信息比率由 2.45 提高至 2.54，月度最大回撤由 3.60% 收窄至 2.59%；2026 年超额收益由 5.11% 提高至 9.25%。在沪深 300 中，PureAlpha 未能提高长期收益中枢，超额年化收益和信息比率有所下降，但月度胜率由 69.09% 提高至 80.00%，跟踪误差和最大回撤略有改善。这说明 WPE 行为指纹信息在个股差异更充分的中证 1000 和中证 500 中更容易转化为收益，而在成分数量较少、机构覆盖充分且组合约束更强的沪深 300 中，当前模型更多体现为收益稳定性上的补充。

综合来看，本报告并不试图以行为指纹替代传统因子，也不认为表示学习能够消除市场风格变化带来的全部风险。WPE 的价值在于提供一套比单一量价指标更完整的行为坐标，CDE 则负责将这一行为表示转化为结构化的选股信号。实证结果表明，WPE 指纹包含传统风格、行业和普通 OHLCV 之外的信息，PureAlpha 在控制市值和行业后仍保持较强的截面排序能力，并能够在中证 1000 和中证 500 指数增强中提供明显增益。

未来研究可以沿几个方向继续推进：（1）进一步分析五个行为房间和 128 维指纹空间的经济含义，完善历史状态检索、行为聚类、主题拥挤和异常监测工具。（2）在不破坏 WPE 收益解耦原则的前提下，引入更丰富的下游信息，例如基本面、分析师预期、事件和高频微观结构特征，以及我们之前其他报告中手工挖掘的因子簇等，以增强风格内个股选择能力。（3）进一步引入市场环境信息，对行为指纹进行条件化解读。同一种资金流、成交活跃度或撤单行为，在不同市场环境下可能对应不同的收益含义。未来研究的重点不应是机械剔除行为信号中的 Beta 信息，而是识别市场风险偏好、流动性、波动水平和主导风格等环境状态，并据此动态调整“行为-收益”的映射关系。这样既保留行为指纹所包含的完整市场信息，也能够降低固定收益映射在环境切换时失效的风险。

量价指纹仍处于持续迭代阶段，但本次研究已经表明，从“计算若干指标”走向“学习交易行为表示”，能够为传统量价研究和指数增强策略提供具有实际价值的新信息来源。

风险提示

以上结论均基于历史数据和模型的测算，如果市场环境和结构发生剧烈改变，不排除模型失效的可能性；

单模型的收益可能存在较大波动，实际应用需结合资金管理、风险控制等方法；

模型测算可能存在相对误差，不构成实际投资建议。

免责声明

国盛证券股份有限公司（以下简称“本公司”）具有中国证监会许可的证券投资咨询业务资格。本报告仅供本公司的客户使用。本公司不会因接收人收到本报告而视其为客户。在任何情况下，本公司不对任何人因使用本报告中的任何内容所引致的任何损失负任何责任。

本报告的信息均来源于本公司认为可信的公开资料，但本公司及其研究人员对该等信息的准确性及完整性不作任何保证。本报告中的资料、意见及预测仅反映本公司于发布本报告当日的判断，可能会随时调整。在不同时期，本公司可发出与本报告所载资料、意见及推测不一致的报告。本公司不保证本报告所含信息及资料保持在最新状态，对本报告所含信息可在不发出通知的情形下做出修改，投资者应当自行关注相应的更新或修改。

本公司力求报告内容客观、公正，但本报告所载的资料、工具、意见、信息及推测只提供给客户作参考之用，不构成任何投资、法律、会计或税务的最终操作建议，本公司不就报告中的内容对最终操作建议做出任何担保。本报告中所指的投资及服务可能不适合个别客户，不构成客户私人咨询建议。投资者应当充分考虑自身特定状况，并完整理解和使用本报告内容，不应视本报告为做出投资决策的唯一因素。

投资者应注意，在法律许可的情况下，本公司及其本公司的关联机构可能会持有本报告中涉及的公司所发行的证券并进行交易，也可能为这些公司正在提供或争取提供投资银行、财务顾问和金融产品等各种金融服务。

本报告版权归“国盛证券股份有限公司”所有。未经事先本公司书面授权，任何机构或个人不得对本报告进行任何形式的发布、复制。任何机构或个人如引用、刊发本报告，需注明出处为“国盛证券研究所”，且不得对本报告进行有悖原意的删节或修改。

分析师声明

本报告署名分析师在此声明：我们具有中国证券业协会授予的证券投资咨询执业资格或相当的专业胜任能力，本报告所表述的任何观点均精准地反映了我们对标的证券和发行人的个人看法，结论不受任何第三方的授意或影响。我们所得报酬的任何部分无论是在过去、现在及将来均不会与本报告中的具体投资建议或观点有直接或间接联系。

投资评级说明

投资建议的评级标准		评级	说明
评级标准为报告发布日后的 6 个月内公司股价（或行业指数）相对同期基准指数的相对市场表现。其中 A 股市场以沪深 300 指数为基准；新三板市场以三板成指（针对协议转让标的）或三板做市指数（针对做市转让标的）为基准；香港市场以摩根士丹利中国指数为基准，美股市场以标普 500 指数或纳斯达克综合指数为基准。	股票评级	买入	相对同期基准指数涨幅在 15%以上
		增持	相对同期基准指数涨幅在 5%~15%之间
		持有	相对同期基准指数涨幅在 -5%~+5%之间
		减持	相对同期基准指数跌幅在 5%以上
	行业评级	增持	相对同期基准指数涨幅在 10%以上
		中性	相对同期基准指数涨幅在 -10%~+10%之间
		减持	相对同期基准指数跌幅在 10%以上

国盛证券研究所

北京

地址：北京市丰台区丽泽路 22 号院新华社国家金融信息大厦西塔 B 座 38 层
 邮编：100077
 邮箱：gsresearch@gszq.com

南昌

地址：南昌市红谷滩新区凤凰中大道 1115 号北京银行大厦
 邮编：330038
 传真：0791-86281485
 邮箱：gsresearch@gszq.com

上海

地址：上海市浦东新区南洋泾路 555 号陆家嘴金融街区 22 栋
 邮编：200120
 电话：021-38124100
 邮箱：gsresearch@gszq.com

深圳

地址：深圳市福田区福华三路 100 号鼎和大厦 24 楼
 邮编：518033
 邮箱：gsresearch@gszq.com